

第一章：IPython、Jupyter、Google Colab 入门

学习大模型，几乎绕不开 Jupyter Notebook 和 Google Colab。本篇先把这三个常用概念讲清楚，再讨论 Colab 上的模型选型，最后用 Qwen3-8B 跑一个真实的大模型示例，建立直观感受。

想直接跑示例？点这里  [Open in Colab](#)。

硬件门槛：Colab 免费版 T4（15 GB）✓。本章 ipynb 用 bitsandbytes 4-bit 量化加载 Qwen3-8B，权重约 5.5 GB，T4 完全够用。打开 ipynb 前请先在 Colab 菜单 Runtime → Change runtime type 里切到 GPU。

一、三者的关系

Python（编程语言/解释器）

↓ 在其之上构建

IPython（增强的交互式 shell + 内核）

↓ 作为内核被使用

Jupyter（基于浏览器的 Notebook 前端）

↓ 部署到云端

Google Colab（Google 托管的免费 Jupyter 服务）

Python / IPython / Jupyter / Colab 的层次关系



可以这样理解：

- IPython 是引擎
- Jupyter 是给引擎装上的方向盘和仪表盘
- Google Colab 是把整辆车放到云端，让你随时上车开

二、IPython (Interactive Python)

2.1 是什么

IPython 是一个增强版的 Python 交互式解释器。比 Python 自带的 `>>>` REPL 强大得多，是 Jupyter Notebook 的底层内核 (kernel) ——你在 Notebook 里写的所有 Python 代码，本质上都由 IPython 执行。

2.2 核心增强特性

特性	示例	作用
Magic 命令	<code>%timeit sum(range(1000))</code>	测量执行时间、运行脚本、加载扩展等
Shell 命令	<code>!pip install numpy</code>	<code>!</code> 前缀直接执行系统命令
Tab 自动补全	<code>np.ar<TAB></code>	弹出 <code>array</code> 、 <code>arange</code> 等候选
帮助系统	<code>len?</code> / <code>np.array??</code>	<code>?</code> 看文档, <code>??</code> 看源码
历史输入输出	<code>Out[1]</code> 、 <code>_</code>	可引用之前的执行结果
富文本输出	<code>display(Markdown(...))</code>	渲染 HTML、图片、Markdown、LaTeX

2.3 Magic 命令的两种形式


- `%` 行魔法：只作用于当前行，例如 `%time func()`
- `%%` 单元格魔法：作用于整个单元格，必须写在第一行，例如 `%%capture`


三、Jupyter Notebook

3.1 是什么


Jupyter 是一个基于浏览器的交互式计算环境，把代码、文本、图表、公式融合到一个 `.ipynb` 文档中。它的命名 "Ju-pyt-er" 暗指 Julia + Python + R 三种语言。

3.2 架构





Jupyter 三层架构：前端 / Kernel / 解释器



Jupyter 是壳，IPython 是最常用的内核。Jupyter 项目本身是 2014 年从 IPython 拆分出来的。

3.3 Notebook 的结构

- Cell (单元格)：基本编辑单位，分为
 - Code Cell: 写并执行代码
 - Markdown Cell: 写文档
 - Raw Cell: 原始文本 (不执行也不渲染)
- 每个 cell 用 `Shift + Enter` 执行

3.4 常用快捷键

Jupyter 的快捷键分两种模式：编辑模式 (cell 内有光标、正常打字) 和命令模式 (按 `Esc` 退出编辑、整个 cell 被选中，此时按键就是操作命令)。下面是 Jupyter Notebook / JupyterLab 的原生键位：

快捷键	模式	作用
Shift + Enter	任意	运行当前 cell 并跳到下一格
Ctrl + Enter	任意	运行当前 cell, 停留在原处
B / A	命令模式	在下方 / 上方新建 cell
D D (连接两次 D)	命令模式	删除当前 cell
M	命令模式	切换为 Markdown cell
Y	命令模式	切换为 Code cell

注意：Colab 的键位和原生 Jupyter 不一样——它把命令模式单键统一改成了 `Ctrl + M` 前缀的组合键：`Ctrl + M B` 新建、`Ctrl + M D` 删除、`Ctrl + M M` / `Ctrl + M Y` 切换 cell 类型。下一节进入 Colab 后用的就是这一套。

四、Google Colab

4.1 是什么

Google Colab (Colaboratory) 是 Google 提供的免费云端 Jupyter Notebook 服务，浏览器打开即用，无需任何本地配置，并且免费提供 GPU/TPU——这是学习大模型的关键。

4.2 核心优势

特性	说明
零配置	浏览器打开即用，无需安装 Python
免费 GPU/TPU	免费版含 T4 GPU，Pro/Pro+ 提供 A100、L4 等
云端存储	Notebook 自动保存到 Google Drive
协作共享	像 Google Docs 一样可多人协同
预装环境	NumPy、PyTorch、TensorFlow、transformers 等已装好

4.3 局限

限制	说明
会话时长	免费版最长约 12 小时，闲置 ~90 分钟会断开

限制	说明
资源不保证	高峰期可能拿不到 GPU
临时文件易失	<code>/content/</code> 下的文件在会话结束后清空
不适合长任务	训练大模型建议升级 Pro+ 或用其他云平台

4.4 基本使用步骤

- 1. 访问 <https://colab.research.google.com> 并登录
- 2. 文件 → 新建笔记本
- 3. 代码执行程序 → 更改运行时类型 → 硬件加速器 → GPU 启用 GPU
- 4. 在 cell 中写 Python 代码, `Shift + Enter` 执行
- 5. 用 `!pip install xxx` 安装额外的库
- 6. 用 `from google.colab import drive; drive.mount('/content/drive')` 挂载 Google Drive

4.5 在 VS Code 中使用 Colab

浏览器版的 Colab 编辑体验一般（无智能补全、无 Git 集成、调试工具弱）。Google 官方提供了 Google Colab 扩展，可以让你在 VS Code 里写代码、用 Colab 的 GPU 跑——本地编辑器 + 云端算力，体验最佳。

为什么用 VS Code 接 Colab

优势	说明
更好的编辑器	Pylance 智能补全、类型提示、错误高亮
Git 原生集成	直接用 VS Code 的 Source Control 面板提交
更强的调试	设断点、查看变量、调用栈，比浏览器友好
本地文件访问	直接编辑、保存到本地工作区
多文件管理	同时打开 <code>.py</code> 、 <code>.ipynb</code> 、 <code>.md</code> ，与本项目结构一致
AI 辅助	可结合 Copilot、Claude Code 等

安装与配置（推荐方式）

- 1. 安装扩展
 - VS Code 扩展市场搜索 "Google Colab"（发布者：Google）
 - 点击安装

2. 登录 Google 账号

- 安装后左侧栏出现 Colab 图标
- 点击 → 选择 Sign in → 浏览器跳转完成 OAuth 授权

3. 打开 / 新建 Notebook

- `Ctrl/Cmd + Shift + P` → 输入 `Colab: New Notebook`
- 或直接打开本地 `.ipynb` 文件

4. 连接 Colab 运行时

- Notebook 右上角点击 "Connect"
- 选择运行时类型: CPU / T4 / L4 / A100 / H100 / TPU
- 等待几十秒, 状态变为绿色即连接成功

5. 运行代码

- 完全和浏览器版 Colab 一样, `Shift + Enter` 执行 cell
- GPU、显存、文件系统都来自云端 Colab

与浏览器版的差异 (容易踩坑)

项目	浏览器 Colab	VS Code 插件
<code>%%capture</code> 位置	容忍前面有空行	必须严格在第一行, 否则 <code>Line magic function not found</code>
挂载 Drive	弹窗授权	同样弹窗, 但可能需切回浏览器完成
<code>%matplotlib inline</code>	默认开启	有时需手动加上
进度条显示	tqdm 正常	tqdm 偶尔渲染异常, 可用 <code>tqdm.notebook</code>
会话保持	关闭浏览器即断开	VS Code 关闭也会断开, 行为一致
快捷键	Colab 自定义	用的是 VS Code Notebook 快捷键 (如 <code>Esc</code> 、 <code>Enter</code> 切换模式)

五、大模型选型：Colab 上跑什么模型最合适

学习大模型时模型选择的关键约束是显存——免费 Colab 的 T4 GPU 只有 15GB 显存。下面按显存档位推荐几个表现优秀的开源模型，并说明如何用量化技术在小显存上跑大模型。

5.1 Colab 显存档位

运行时	GPU	显存	备注
免费版	T4	15 GB	默认，最常用
Pay-as-you-go	L4	24 GB	更好的性价比
Pro	A100	40 GB	可跑 14B–34B 模型
Pro+	A100	40 GB	同 Pro 的 GPU，但算力配额更高、可后台运行、会话更长

显存估算经验法则：

- BF16/FP16 加载，显存 $\approx$ 参数量 $\times$ 2 GB（7B 模型 $\approx$ 14 GB）
- 4-bit 量化加载，显存 $\approx$ 参数量 $\times$ 0.7 GB（7B 模型 $\approx$ 5 GB）

5.2 推荐模型（按效果由强到弱）

首选：Qwen3-8B（阿里）

```
model_id = "Qwen/Qwen3-8B"
```

- 优势：中英文一流、指令遵循好、原生 32k 上下文（YaRN 可扩 128k）、独有「思考/非思考模式」切换
- 显存：BF16 约 16GB（T4 装不下），4-bit 量化约 5.5GB（推荐）
- 依赖：需要 `transformers >= 4.51.0`
- 命名变化：Qwen3 系列把 base 与 chat 合并到同一仓库，仓库名不再带 `-Instruct` 后缀——`Qwen/Qwen3-8B` 即 chat 模型，`Qwen/Qwen3-8B-Base` 才是基座
- 思考模式（重要）：Qwen3 通过 `apply_chat_template(..., enable_thinking=True/False)` 切换
 - `enable_thinking=True`（默认）：先输出 `<think>...</think>` 推理过程，再给最终回答；适合数学、代码、逻辑题
 - `enable_thinking=False`：直接给答案，速度快；适合普通对话
 - 思考模式下不能用贪心解码（`do_sample=False`），会出现重复退化；必须采样

- 官方推荐采样参数:

模式	temperature	top_p	top_k	min_p
思考	0.6	0.95	20	0
非思考	0.7	0.8	20	0

备选: Qwen2.5-7B-Instruct (阿里, 老一代)

```
model_id = "Qwen/Qwen2.5-7B-Instruct"
```

- 没有思考模式、API 更简单, 老教程兼容性最好
- 4-bit 量化约 5GB

Llama-3.1-8B-Instruct (Meta)

```
model_id = "meta-llama/Llama-3.1-8B-Instruct"
```

- 优势: 开源生态最完善、教程最多、几乎所有论文/项目的基线
- 显存: BF16 约 16GB (T4 装不下, 需量化), 4-bit 约 6GB
- 注意: 需要在 Hugging Face 申请访问 (填表后几分钟通过)

Gemma-2-9B-it (Google)

```
model_id = "google/gemma-2-9b-it"
```

- 优势: Google 出品、9B 比 7B 多一档、综合质量好
- 显存: BF16 约 18GB (T4 装不下, 需量化), 4-bit 约 7GB

替补: Phi-3.5-mini-instruct (微软)

```
model_id = "microsoft/Phi-3.5-mini-instruct"
```

- 3.8B 参数但综合表现接近 7B 模型
- 显存: BF16 约 8GB, T4 直接全精度跑无压力
- 适合谁: 想快速迭代、不想折腾量化的入门阶段

进阶（需 Colab Pro / A100）

模型	参数量	备注
Qwen/Qwen3-14B	14B	思考模式下推理更强
Qwen/Qwen3-32B	32B	4-bit 量化后 $\approx$ 20GB，A100 可跑
Qwen/Qwen3-30B-A3B	30B（MoE，激活 3B）	速度接近 3B，效果接近 30B

5.3 综合对比

8B 量级 chat 模型在常见基准的近似排名：

模型	MMLU	中文能力	指令遵循	综合
Qwen3-8B（思考模式）	76	★★★★★	★★★★★	★★★★★
Qwen3-8B（非思考）	74	★★★★★	★★★★★	★★★★★
Qwen2.5-7B-Instruct	74	★★★★★	★★★★★	★★★★★
Llama-3.1-8B-Instruct	73	★★★	★★★★★	★★★★★
Gemma-2-9B-it	71	★★★	★★★★★	★★★★★
Phi-3.5-mini-instruct	69	★★★	★★★★★	★★★★

5.4 关于 4-bit 量化

是什么：用更少的位数表示同一个数

模型权重训练时用的是 16-bit 浮点数（BF16/FP16），每个数占 2 字节。量化（Quantization）就是把这些浮点数用更少的位数（如 8-bit、4-bit 整数）来近似表示，从而把模型体积压小、显存占用降下来。

精度	每个权重占用	8B 模型权重大小
FP32	4 字节	32 GB
BF16 / FP16	2 字节	16 GB
INT8	1 字节	8 GB
INT4	0.5 字节	4 GB


原理：把连续浮点值映射到离散整数

朴素 INT4 量化的做法：

1. 把权重张量按"块"（如每 64 或 128 个数为一组）切开
2. 在每块里找出最大绝对值 `absmax`
3. 计算缩放系数 `scale = absmax / 7`（4-bit 有符号整数范围是 -8 到 7）
4. 每个浮点数除以 `scale`、四舍五入成整数，存为 INT4
5. 推理时再乘回 `scale`，还原成近似的浮点值参与矩阵乘法

这样每个权重从 2 字节压到 0.5 字节，体积降至 1/4。代价是引入了"舍入误差"——不过大模型权重整体冗余度高，少量误差对最终输出的影响很小。

4-bit (INT4) 量化流水线：以 8 个权重为例



一个手算示例：8 个权重走一遍 INT4 量化

为了让上面 5 步落到具体数字上，下面拿一个块大小 = 8 的简化情形手动算一遍。先解释两个会用到的概念：

- `absmax`: absolute maximum, 张量中绝对值最大的那个数（不看正负号，只看大小）。
- INT4 有符号整数范围：4 位二进制能表示 $2^4 = 16$ 个整数；按补码编码成有符号整数就是 $\{-8, -7, \dots, 6, 7\}$ ，共 16 个值。

假设这一块里有 8 个 BF16 权重：

$$W = [0.42, -1.23, 0.78, 1.40, -0.34, 1.05, -0.91, 0.12]$$

Step 1: 找 absmax

$$\text{absmax} = \max_i |w_i| = 1.40$$

Step 2: 算 scale（缩放系数）

把 absmax 映射到 INT4 正侧最大值 7，让最大权重正好"吃满"量化范围：

$$\text{scale} = \frac{\text{absmax}}{7} = \frac{1.40}{7} = 0.2$$

Step 3: 量化（每个 w_i 除以 scale，四舍五入到最近的 INT4 整数）

原值 w_i	w_i/scale	取整后 q_i （INT4）
0.42	2.10	2
-1.23	-6.15	-6
0.78	3.90	4
1.40	7.00	7
-0.34	-1.70	-2
1.05	5.25	5
-0.91	-4.55	-5
0.12	0.60	1

存储时只需要保留这 8 个 INT4 整数和 1 个 scale。

Step 4: 反量化（推理时把 INT4 还原成近似浮点 $\hat{w}_i = q_i \cdot \text{scale}$ ）

q_i	反量化值 $\hat{w}_i$	与原值误差 $\hat{w}_i - w_i$
2	0.40	-0.02
-6	-1.20	+0.03
4	0.80	+0.02
7	1.40	0.00
-2	-0.40	-0.06
5	1.00	-0.05
-5	-1.00	-0.09

q_i	反量化值 $\hat{w}_i$	与原值误差 $\hat{w}_i - w_i$
1	0.20	+0.08

两个直观结论：

- 1. 存储开销。本来 8 个 BF16 权重需要 $8 \times 2 = 16$ 字节；量化后是 $8 \times 0.5 = 4$ 字节（INT4 权重）+ 2 字节（一个 FP16 scale）= 6 字节，约 1/2.7。这里块大小只有 8，scale 占比偏高；真实 NF4 默认块大小是 64，scale 摊到每个权重只多 $2/64 \approx 0.031$ 字节，整体接近理论上限 1/4。
- 2. 误差量级。任何一个权重的反量化误差都不超过 $scale/2 = 0.1$ （这是四舍五入的最坏情形）。单点相对误差最大约 $0.09/0.91 \approx 10\%$ 看着不小，但矩阵乘法是大量元素求和——独立的小误差有正有负、互相抵消，最终输出的偏差通常远小于单点误差。这就是 4-bit 量化"看似激进却仍可用"的根本原因。

为什么是 4-bit：精度和体积的平衡点

位数	显存压缩比	质量损失（典型 7-8B 模型）	评价
8-bit	1/2	< 0.5%（近乎无损）	显存优势不够大
4-bit	1/4	1-2%	平衡点：体积大幅缩小、损失可接受
3-bit	3/16	5-10%	损失明显，仅特定校准方案勉强可用
2-bit	1/8	> 15%	损失太大，研究阶段

4-bit 是社区公认的"够用底线"——再低，损失就开始显著影响生成质量。实践中，bitsandbytes 提供的 4-bit 实现还做了两个工程优化：

- NF4（NormalFloat4）：神经网络权重大致服从正态分布，朴素 INT4 用等距量化点不是最优。NF4 把 16 个量化点放在正态分布的等概率分位数上，让"权重密集的区域"分得更细，相同位数下损失更小。
- 双量化（double quantization）：每个块都有自己的 `scale` 系数，而 `scale` 本身也是浮点数。把这些 `scale` 再做一次 8-bit 量化，每个权重再省 ~0.4 比特。8B 模型大概再省 0.4 GB。

还有 GPTQ / AWQ 等"校准量化"方案——量化前用一小批样本数据校准每层的量化参数，质量损失通常比 NF4 再低 0.5%。本章用 NF4 是因为它"开箱即用"、不需要准备校准数据。

反量化会拖慢推理速度么

这是看完上面"压缩—反量化"流程后最自然的疑问：每次矩阵乘法（matmul）之前都要把权重还原成 BF16，

$$\hat{w}_i = q_i \cdot scale$$

是不是凭空多了一道工序？直觉上"会变慢"，但在大模型单 batch 推理（也就是日常 chat 场景）下，4-bit 通常反而比 BF16 更快。要解释清楚需要先引入几个概念：

- 显存与显存带宽：模型权重和 KV cache 都存在 GPU 显存（VRAM）里，每次 matmul 都要先把权重从显存搬到 SM 内的寄存器/SRAM 才能参与计算，"搬得多快"由显存带宽决定。数据中心卡（A100/H100）用的是紧贴芯片封装的 HBM（High Bandwidth Memory，高带宽显存）；T4 这类老卡用的是普通 GDDR6（320 GB/s，约为 A100 HBM2e 1.5 TB/s 的 1/5），但"权重必须先搬运再计算"这一点是一样的。
- memory-bound（内存带宽瓶颈）：瓶颈在"从显存把数据搬到计算单元"上——计算单元大多时间空转等数据。
- compute-bound（算力瓶颈）：瓶颈在浮点运算量上——数据已经在手边，但 matmul 还没算完。

LLM 推理天然分两个阶段，瓶颈不一样：

阶段	做什么	主要瓶颈
prefill	把整段 prompt 一次性走过模型，得到第一个新 token 的 logits	compute-bound（一份权重被 prompt 里很多 token 复用，FLOPs 摊得多）
decode	每生成一个新 token 都要走一次完整前向	memory-bound（一份权重读进来只服务一个 token）

用 T4 + Qwen3-8B 估算一下单 token 耗时

T4 的两项关键指标：显存（GDDR6）带宽约 320 GB/s，FP16 Tensor Core 算力约 65 TFLOPS。每生成一个 token，所需资源的耗时下限：

资源	公式	耗时下限
从显存搬一遍 4-bit 权重（≈ 5.5 GB）	$5.5\text{ GB}/320\text{ GB/s}$	~17 ms
单 token 浮点矩阵乘运算量	$2 \times 8B/(65 \times 10^{12}\text{ FLOPS})$	~0.25 ms

这里的 $2 \times$ 参数量 是 LLM 单 token 前向的常用估算：每个权重参与一次乘法 + 一次加法。

带宽下限是算力下限的将近 70 倍——计算单元绝大多数时间在"等数据"，反量化那一点额外乘法被这个等待时间完全淹没。

同样 8B 模型如果用 BF16（在 T4 上其实装不下，这里只做对照），权重 16 GB，带宽下限 $16/320 \approx 50\text{ ms/ token}$ ——是 4-bit 的近 3 倍。所以 4-bit decode 不仅没变慢，反而更快。

什么时候 4-bit 反而会变慢

- prefill 长 prompt / 训练 / 大 batch 推理：这些是 compute-bound，每份权重被复用很多次，反量化那一道额外算力开销暴露出来，4-bit 可能比 BF16 略慢。

- T4 这类老卡更明显：没有原生 INT4 Tensor Core，bitsandbytes 的 dequant 内核也没和 matmul 做深度融合（专用方案如 AWQ + Marlin、GPTQ + ExLlamaV2 把 dequant 融合进 matmul kernel，prefill 也能追上甚至超过 BF16）。

在本章的场景下

T4 只有 15 GB 显存：

- BF16 加载 8B 权重需要 ~16 GB —— 装不下，根本无从对比
- 4-bit 加载 8B 权重需要 ~5.5 GB —— 能跑，且 chat decode 单 token 速度相当流畅

所以选 4-bit 不是"拿速度换显存"——是"不量化连跑都跑不起来；而量化后单 token 速度还相当不错"。先有可用、再谈速度，是这一阶段刻意的工程取舍。

本章的选择

`bitsandbytes` 库与 transformers 无缝集成，下文示例采用 4-bit NF4 + 双量化 加载 Qwen3-8B，权重从 16 GB 压到约 5.5 GB，让免费 T4 GPU（15 GB 显存）也能流畅运行。

5.5 Colab Pro 用户的配卡策略

Colab Pro 提供 ~100 计算单元/月，可访问 L4 / A100 / v5e / v6e，并支持后台执行与更长会话。但不同 GPU 的算力消耗差异很大，需要按场景规划。

算力消耗速率

GPU	计算单元/小时	100 单元能用多久
T4	~2	~50 小时
L4	~5	~20 小时
A100	~12	~8 小时

A100 消耗最快、T4 最省——8 小时 vs 50 小时差 6 倍。学习场景最忌讳被算力卡住中断，所以要分场景配卡。

分场景推荐

场景	推荐 GPU	理由
跑教程、调通代码、Debug	T4	消耗最低（~2 单元/小时），省单元给后面

场景	推荐 GPU	理由
日常学习主力（推理、对比）	L4	24GB 显存够 7B BF16 + 13B 4-bit；compute 受限场景比 T4 明显快，decode 受显存带宽限制提升有限
微调（LoRA）、跑 14B+ 模型	A100	HBM2e 带宽 1.5TB/s，跑 32B 4-bit 也行
数据处理、画图、写文档	CPU	不消耗计算单元

学习路径（按阶段递进）

阶段 1：基础概念

- T4 + Qwen3-8B (4-bit NF4)
- 跑教程、上手 tokenizer、采样策略、思考模式开关，省单元

阶段 2：模型对比、Prompt 工程

- L4 + Qwen3-8B (FP16) / Qwen3-14B (4-bit)
- 24GB 显存够 8B 全精度，或单个 14B 量化跑长链思考

阶段 3：微调、深入原理

- A100 + Qwen3-14B (BF16) / Qwen3-32B (4-bit) / Qwen3-30B-A3B (MoE 4-bit)
- 集中 1-2 天用，跑完立即释放

注：T4 是 Turing 架构，不原生支持 BF16——在 T4 上加载半精度模型时要用 `torch_dtype=torch.float16`，到 L4/A100（Ampere 及以上）才能用 BF16。

六、实战示例：在 Colab 中加载并运行 Qwen3-8B

下面这个例子在 Colab 中加载阿里的 Qwen3-8B（8B 参数、中英文一流、带「思考模式」），通过 4-bit 量化让免费 T4 GPU（15GB 显存）即可流畅运行。

6.1 准备工作

打开 Colab，确保已切换到 GPU 运行时（菜单 → 代码执行程序 → 更改运行时类型 → GPU）。

6.2 完整代码（含详细注释）

Cell 0 先确认 GPU 在线：

```
# =====
# Cell 0: 检查 GPU 是否可用
# =====
# 大模型示例最常见的失败原因不是代码错，而是没切到 GPU 运行时。
```



```
# 先一眼确认 GPU 在线，再继续后面的步骤，避免白白下载几 GB 权重。
import torch

print("CUDA available:", torch.cuda.is_available())
if torch.cuda.is_available():
    print("Device:", torch.cuda.get_device_name(0))
    # 显存以 GB 为单位打印，T4 应显示约 14.7 GB
    total_mem = torch.cuda.get_device_properties(0).total_memory / 1024**3
    print(f"Total VRAM: {total_mem:.1f} GB")
else:
    # 切换方式：菜单 → 代码执行程序 → 更改运行时类型 → 硬件加速器 → T4 GPU
    print("⚠ 当前没有 GPU，请切换到 GPU 运行时再继续")
```

Cell 1 安装依赖：

```
%%capture
# =====
# Cell 1: 安装/升级依赖库
# =====
# 重要：%%capture 是单元格魔法命令，必须是 cell 的第一行（前面不能有任何内容，包括注释）
# 否则 Jupyter / VS Code 会将其当作 line magic 解析，报错：
#   UsageError: Line magic function `%%capture` not found.
# 它的作用：捕获整个 cell 的输出，让 pip install 几十行的安装日志不显示在屏幕上
# ! 前缀让 IPython 把这一行交给系统 shell 执行（而非 Python 解释器）
# -q 表示 quiet 模式，进一步减少 pip 的输出噪音
# -U 表示 upgrade，如果已装则升级到最新版
# transformers>=4.51: Qwen3 系列要求至少 4.51，否则 chat template 不识别 enable_thinking
# accelerate:          分布式/混合精度加速，加载大模型时几乎是必需依赖
# bitsandbytes:        提供 8-bit / 4-bit 量化能力，让大模型在小显存上跑起来
!pip install -q -U "transformers>=4.51" accelerate bitsandbytes
```

Cell 2 用 4-bit NF4 + 双量化加载模型与分词器：

```
# =====
# Cell 2: 加载模型与分词器（采用 4-bit 量化）
# =====
# AutoModelForCausalLM: "自动选择 CausalLM 类"的工厂类
#   CausalLM = Causal Language Model, 因果语言模型，即 GPT 这类自回归生成模型
# AutoTokenizer:        根据模型 ID 自动选择对应的分词器实现
# BitsAndBytesConfig:    配置 bitsandbytes 的量化参数
from transformers import AutoModelForCausalLM, AutoTokenizer, BitsAndBytesConfig
import torch

# Hugging Face Hub 模型 ID, 格式 "组织名/模型名"
# Qwen3 系列把 base 与 chat 合并到同一仓库，仓库名不再带 "-Instruct" 后缀：
#   "Qwen/Qwen3-8B"      → chat 模型（本章使用）
#   "Qwen/Qwen3-8B-Base" → 基座，只做续写不按对话回答
model_id = "Qwen/Qwen3-8B"

# 4-bit 量化配置（原理与手算示例见「关于 4-bit 量化」一节）
quant_config = BitsAndBytesConfig(
    load_in_4bit=True,                # 启用 4-bit 量化
    bnb_4bit_compute_dtype=torch.float16, # 反量化后矩阵乘法的 dtype (T4 不原生支持 BF16; L4/A100 可改 torch.bfloat16)
    bnb_4bit_quant_type="nf4",        # 量化点采用 NF4 (NormalFloat4)
    bnb_4bit_use_double_quant=True,    # 启用双量化，再把每块的 scale 也量化一次
)

# from_pretrained() 自动从 Hugging Face Hub 下载权重并缓存到 ~/.cache/huggingface/
```



```
# 下次加载同一模型不会重复下载
model = AutoModelForCausalLM.from_pretrained(
    model_id,
    device_map="auto",          # 让 accelerate 自动分配模型层；单卡时等价于全部放到 GPU
    quantization_config=quant_config, # 应用上面定义的 4-bit 量化配置
)

# 加载与模型配对的分词器：负责文本 ↔ token id 的双向转换
tokenizer = AutoTokenizer.from_pretrained(model_id)
```

Cell 3 构造对话并生成回答：

```
# =====
# Cell 3: 构造对话并让模型生成回答（非思考模式 / 普通对话）
# =====
# Qwen3 chat 模型期望的输入是"对话格式"，每条消息有 role 和 content
# role 通常是 "system"（系统提示）/ "user"（用户）/ "assistant"（模型回答）
messages = [
    {"role": "system", "content": "你是一个乐于助人的 AI 助手，回答简洁明了。"},
    {"role": "user", "content": "用一句话解释什么是 Transformer 架构。"},
]

# apply_chat_template() 会按照模型训练时使用的对话模板格式化输入
# 不同模型的模板不同（Qwen / Llama / Phi 各自有自己的特殊 token）
# add_generation_prompt=True 在末尾追加"轮到 assistant 回答"的提示符
# enable_thinking=False 关闭"思考模式"——直接输出答案，不先打 <think>...</think> 推理过程
# 想要更强的逻辑/数学/代码能力时，把它改成 True，并提高 max_new_tokens 给足思考空间
# return_tensors="pt" 直接返回 PyTorch 张量（pt = PyTorch）
# return_dict=True 让返回类型固定为 BatchEncoding（含 input_ids、attention_mask）
# 注意：新版 transformers (≥4.45) 在某些情况下默认返回 BatchEncoding 而非 Tensor
# 若把 BatchEncoding 直接作为位置参数传给 generate()，会触发：
#   KeyError: 'shape' → AttributeError
# 所以推荐显式 return_dict=True + 用 **inputs 解包
inputs = tokenizer.apply_chat_template(
    messages,
    add_generation_prompt=True,
    enable_thinking=False,
    return_tensors="pt",
    return_dict=True,
).to(model.device) # 把输入张量移到模型所在设备，与模型在同一设备才能计算

# Qwen3 对话场景的终止符是 <|im_end|>（标记一轮消息说完了）。它在 tokenizer_config.json
# 里被静态配置成 eos_token——所以 Qwen3 的 tokenizer.eos_token_id 拿到的就是 <|im_end|>;
# 另有一个通用文本结束符 <|endoftext|>，仓库的 generation_config.json 默认把两者都列为终止 token。
# 这里把两个 id 都显式查出来传给 generate()，让"在哪停"在代码里看得见；
# 注意：显式传 eos_token_id 会整体覆盖 generation_config 的默认列表——要传就两个都带上
im_end_id = tokenizer.convert_tokens_to_ids("<|im_end|>")
endoftext_id = tokenizer.convert_tokens_to_ids("<|endoftext|>")

# generate() 是 transformers 的统一文本生成接口
# torch.no_grad() 表示推理过程不计算梯度，节省显存并加速
with torch.no_grad():
    outputs = model.generate(
        # **inputs 把字典解包为 input_ids=..., attention_mask=...
        # 显式传 attention_mask 还能避免 padding 干扰，比只传 input_ids 更稳
        **inputs,
        # max_new_tokens 限制最多生成多少个新 token（不含输入部分）
        # 非思考模式 200 足够；思考模式因为要先输出推理过程，建议 ≥ 2048
        max_new_tokens=200,
        # Qwen3 官方推荐：非思考模式用 temperature=0.7、top_p=0.8、top_k=20
        # ⚠ 思考模式（enable_thinking=True）下不能用贪心解码（do_sample=False），
```

```
# 会出现重复退化; 必须 do_sample=True 配 temperature=0.6、top_p=0.95
do_sample=True,
temperature=0.7,
top_p=0.8,
top_k=20,
# eos_token_id 标记生成结束的 token, 采到列表中任意一个就停止
# <|im_end|> (对话轮结束) + <|endoftext|> (通用结束), 与 generation_config 默认一致
eos_token_id=[im_end_id, endoftext_id],
)

# outputs 形状是 [batch_size, sequence_length], 包含输入 + 生成的全部 token
# 我们只想看新生成的部分, 所以从输入长度处切片
input_length = inputs["input_ids"].shape[-1]
generated_tokens = outputs[0][input_length:]

# decode() 把 token id 列表还原成可读字符串
# skip_special_tokens=True 去掉 <|im_end|> 等特殊标记
response = tokenizer.decode(generated_tokens, skip_special_tokens=True)

print(response)
```

6.3 预期输出

模型会输出类似:

Transformer 是一种基于自注意力机制 (Self-Attention) 的神经网络架构, 通过并行处理序列中所有位置之间的依赖关系, 实现了对长距离上下文的高效建模。

如果把 enable_thinking=False 改成 True、max_new_tokens 调到 2048, 输出会先包含一段 <think>...</think> 推理过程, 再给出最终答案——这是 Qwen3 区别于 Qwen2.5 的核心特性。

6.4 关键概念回顾

通过这个例子, 串起了大模型应用最核心的几个概念:

概念	在代码中的位置
模型权重 (weights)	from_pretrained() 下载并加载
量化 (quantization)	BitsAndBytesConfig(load_in_4bit=True) 4-bit 压缩节省显存
分词器 (tokenizer)	把人类语言 ↔ token id 互转
对话模板 (chat template)	apply_chat_template() 按模型训练时格式构造输入
思考模式 (thinking)	enable_thinking=True/False Qwen3 独有的推理开关

概念	在代码中的位置
设备分配 (device)	<code>device_map="auto"</code> + 输入张量 <code>.to(model.device)</code>
生成策略 (decoding)	<code>do_sample=True</code> 采样 (思考模式必须) / <code>False</code> 贪心 (仅非思考可用)
终止符 (eos)	Qwen3 把对话终止符 <code>< im_end ></code> 配置为 <code>eos_token</code> ; 显式传 <code>eos_token_id</code> 列表会覆盖默认值, 记得连 <code>< endoftext ></code> 一起带上
生成长度	<code>max_new_tokens</code> 控制输出长度

七、本章小结

- IPython 提供了 Magic 命令、shell 集成、富文本显示等增强能力
- Jupyter 是基于浏览器的 Notebook 前端, IPython 是它默认的 Python 内核
- Google Colab 是云端版 Jupyter, 关键卖点是免费 GPU, 非常适合大模型学习与实验
- 模型选型 的核心约束是显存: T4 (15GB) 上推荐 Qwen3-8B + 4-bit 量化
- 量化 (bitsandbytes 4-bit) 让 7B-9B 模型在免费 T4 也能流畅运行, 质量损失通常 < 2%
- Qwen3 的「思考模式」是这一代的核心特性: `enable_thinking=True` 时先输出推理过程再给答案, 并且必须用采样而非贪心解码
- 加载并运行一个开源大模型只需要几十行代码: `from_pretrained` 加载 → `apply_chat_template` 构造输入 → `generate` 生成

下一章我们会把镜头拉近 `generate()` 内部——讲清楚 logits → softmax → temperature → top-k / top-p → 采样 这条流水线, 以及 `do_sample` / `temperature` / `top_p` / `top_k` / `repetition_penalty` 各自数学上做了什么、应该怎么选。