

预备知识 P05: 强化学习够用版——MDP / policy / value / REINFORCE / policy gradient

LLM 训练里"对齐"那一段 (RLHF / PPO / DPO / GRPO / RLVR) 几乎全部建立在强化学习 (Reinforcement Learning, RL) 的语言上。可它的语言又跟前面几章的"监督学习"很不一样: 没有"标签"、要跟"环境"互动、奖励还可能稀疏。

直接读 PPO 论文常常一开篇就被 $\pi_{\theta}(a | s)$ 、 $V^{\pi}(s)$ 、 $A^{\pi}(s, a)$ 、 $\nabla_{\theta} \mathbb{E}_{\tau \sim \pi_{\theta}}[R(\tau)]$ 这一串符号拦住。这一章不做严谨教材式推导, 而是用最少的数学把"够读懂 PPO 入门"的几件事讲清楚:

- MDP (马尔可夫决策过程) 是 RL 的统一语言——状态、动作、奖励、策略
- 策略梯度 (policy gradient) 是把"调参数让奖励变大"形式化下来的一条公式
- REINFORCE 是策略梯度最朴素的实现, 是 PPO / GRPO 的"祖先"
- 把上面这几件映射到 LLM——状态是 prompt + 已生成 token、动作是下一个 token、奖励来自 RM 或可验证规则

读完这一章再去看 PPO / GRPO, 就只是"REINFORCE + 几条防发散的修补"而已。

想直接跑示例? 点这里  Open in Colab。

硬件门槛: 概念章, CPU 即可✓。本章的 REINFORCE 实战用 `gymnasium` 自带的 `CartPole-v1` 环境 + 一个 $4 \rightarrow 32 \rightarrow 2$ 的小策略网络, CPU 几十秒训到收敛。

简单补充一下 `gymnasium` 和 `CartPole-v1`: `gymnasium` 是 OpenAI 原来那个 `gym` 库的官方维护分支 (OpenAI 不再维护后由 Farama Foundation 接手), 提供了一套统一的 RL 环境接口——`env.reset()` 拿初始状态、`env.step(action)` 走一步拿到 (下一状态, 奖励, `terminated`, `truncated`, `info`)。库里"自带"几十个经典 RL 测试环境, `CartPole-v1` 是最入门的一个: 一辆小车上立着一根杆, 状态是 4 维实数 (小车位置、小车速度、杆角度、杆角速度), 动作是 2 个离散值 (向左推 / 向右推), 每撑住一步给 +1 奖励, 杆倒下或撑满 500 步则 episode 结束——满分就是 500。它的好处是状态/动作都极简、CPU 几十秒就能训到收敛, 特别适合验证 REINFORCE 这种基础算法是不是写对了。

一、强化学习在 LLM 对齐中的位置

LLM 的预训练和 SFT 都是监督学习——给定一段文本, 让模型尽量预测出训练数据里的下一个 token。但「让回答更有帮助、更不胡说、更符合人类偏好」这件事, 监督信号难给:

- 同一个 prompt 可以有很多个"好"回答, 没有唯一标签
- "好"是个偏好排序: A 比 B 好, 但说不出 A 是不是"对"
- 有些任务 (数学题、代码题) 有可验证答案, 但中间推理过程没监督

RL 的范式正好对路：让模型自己生成回答，然后用一个"打分器"给它反馈——打分器可以是人工标注训练出的奖励模型（RM），也可以是可验证规则（如代码能不能跑通、数学答案对不对）。模型按"使总分尽可能高"的方向调参数。

这就是 RLHF / RLVR 的内核：

方法	奖励来源
RLHF（如 InstructGPT、Claude）	人类偏好 → 训练 RM → RM 给打分
RLVR（如 DeepSeek-R1 用 GRPO）	可验证答案 → 直接判对错
DPO 系列	不显式做 RL，但可以从 RL 视角推导


要读懂这些，必须先有 RL 的语言。这一章给的就是"语言"。

二、MDP：RL 的统一语言

下面这张图先把"经典 agent-environment 交互闭环"画出来，再把同一套语言映射到 LLM 对齐——本章剩下的所有概念（状态、动作、奖励、策略、轨迹、目标函数、策略梯度）在右侧都能找到 LLM 里的对应物：

RL 交互闭环 + 把它映射到 LLM 对齐

左：经典 agent-environment 循环；右：每一项在 RLHF / GRPO 里对应什么



RLHF / DPO / GRPO 的训练循环 = 经典 RL 闭环 + 一些"防方差爆炸 / 防策略跑偏"的工程修补

2.1 五元组 (S, A, P, R, γ)

马尔可夫决策过程 (Markov Decision Process, MDP) 由五件东西描述:

符号	名字	含义
$\mathcal{S}$	状态空间	所有可能的"环境状态" s
$\mathcal{A}$	动作空间	所有可能的"动作" a
$P(s' s, a)$	转移概率	在 s 选 a 后转到 s' 的概率
$R(s, a)$	奖励函数	在 s 选 a 立刻拿到的标量奖励
$\gamma \in [0, 1]$	折扣因子	未来奖励衰减系数 (无限时长 MDP 要求 $\gamma < 1$ 才能保证回报收敛; 有限时长 / episodic 任务允许 $\gamma = 1$)

马尔可夫性质: 转到下一状态只依赖于当前 (s, a) , 与历史无关。用条件概率写出来就是

$$P(s_{t+1} | s_t, a_t, s_{t-1}, a_{t-1}, \dots, s_0, a_0) = P(s_{t+1} | s_t, a_t)$$

——左边是"看完整段历史再预测下一步", 右边是"只看当前 (s_t, a_t) 就够了", 两者相等就叫马尔可夫性。奖励侧同理: R 也只依赖当前 (s, a) 而不依赖历史。

这条假设是动态规划 (DP) 和绝大多数 RL 算法的根基——正因为"未来只依赖现在", 价值函数 $V(s) / Q(s, a)$ 才能被定义在单个状态/状态-动作对上、policy 才能写成 $\pi(a | s)$ 而不必依赖整条历史。一旦马尔可夫性不成立 (部分可观测、有长程依赖等), 常见的补救是把"最近若干帧"打包成一个新的"状态", 让打包后的新状态重新满足马尔可夫性, 再套这套语言。

最小例子 (一个 4 状态 grid world) :

```
S → s0 → s1 → s2 → goal      γ = 0.9
      a0    a0    a0
状态空间 S = {s0, s1, s2, goal}
动作空间 A = {向右}
转移      P 是确定性: 选 a0 一定走到下一格
奖励      R(s2, a0) = +1    (这一步走到 goal, 给 +1)
           R(s0, a0) = R(s1, a0) = 0    (其余非终止状态都是 0)
```

2.2 一条 trajectory

智能体 (agent) 按某个策略与环境交互, 会产生一条轨迹 (trajectory / episode) :

$$\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \dots, s_{T-1}, a_{T-1}, r_{T-1}, s_T)$$

—— s_0 是初始状态、 a_t 是 t 时刻的动作、 $r_t = R(s_t, a_t)$ 是即时奖励、 $s_{t+1} \sim P(\cdot | s_t, a_t)$ 。 T 是 episode 长度 (CartPole 里走到杆倒下、LLM 里走到生成 EOS)。

顺便解释一下 $s_{t+1} \sim P(\cdot | s_t, a_t)$ 这个记号（概率论的标准写法）：

- $\sim$ 读作"服从……分布"或"从……采样"，例如 $X \sim \mathcal{N}(0, 1)$ 就是" X 服从标准正态"。
- $P(\cdot | s_t, a_t)$ 整个是一个分布——在给定 (s_t, a_t) 的条件下，下一状态的概率分布。中点 $\cdot$ 是占位符，强调"这是个分布"而不是某点的概率值。对比着看： $P(s' | s_t, a_t)$ 是一个标量（在 s' 这点上的概率）； $P(\cdot | s_t, a_t)$ 是整个函数/分布。
- 合起来意思是：下一状态 s_{t+1} 是从这个条件分布里采样出来的随机变量。

CartPole 是确定性环境（给定当前 (s_t, a_t) ，物理仿真按牛顿方程算出唯一的下一状态，没有任何随机性），所以"分布"实际只在唯一的那个下一状态上取概率 1、其余状态都取 0——退化成一个点质量分布；但写成 $\sim P(\cdot | s_t, a_t)$ 能一并覆盖随机环境（如有噪声的仿真、Atari 的随机初始化）。把 P 换成 π_θ （参数为 θ 的策略，在 LLM 里就是带可训练权重 θ 的语言模型本身，给定上文后输出下一 token 的概率分布）、状态换成"已生成的 token 序列"、动作换成"下一个 token"，就是 LLM 解码时熟悉的 $\text{token}_{t+1} \sim \pi_\theta(\cdot | \text{token}_{<t+1})$ 。

2.3 累计回报 G_t 与 γ

从 t 时刻开始的累计折扣回报（return）：

$$G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \cdots = \sum_{k=0}^{T-1-t} \gamma^k r_{t+k}$$

（这里写的是 episodic / 有限时长版本，上界 $T - 1 - t$ 表示"走到终止前还剩多少步"；无限时长 MDP 直接把上界换成 ∞ 即可。本章 CartPole / LLM 都是有限时长任务，沿用上式。）

折扣因子 γ 起两个作用：

- 数学保证收敛：在无限时长 MDP 里只要 $\gamma < 1$ ，几何级数让总和有限；有限时长任务里求和只有有限项，本就不需要 $\gamma < 1$ 来收敛。
- 建模"近期奖励更重要"：人类决策也偏好近期收益； γ 越接近 1 越远视、越接近 0 越短视。

LLM 对齐里 γ 通常取 1（episode 短、奖励出现在终止时一次给齐），所以折扣这件事在 LLM 训练里偶尔被省略；但在 CartPole 这类经典控制 / 长 episode 任务里 $\gamma = 0.99$ 是常用值。

三、策略 policy 与价值 value

3.1 策略 $\pi(a|s)$

策略（policy）是 agent 的"行为方式"：在状态 s 选动作 a 的概率分布。

$$\pi(a | s)$$

策略可以是：

- 确定性的： $a = \pi(s)$ ，给定状态就给一个动作
- 随机的：在 s 状态下按 $\pi(a | s)$ 抽样

带参数的策略 $\pi_\theta(a | s)$ 是一个用 θ 参数化的概率分布——比如一个神经网络，输入 s 输出动作的 logits，过 softmax 就是 Categorical 分布。LLM 本身就是这样一个策略：输入 "prompt + 已生成 token"，输出 "下一个 token 的概率分布"。

3.2 状态价值 V 与动作价值 Q

固定策略 π ，定义两个值函数：

$$V^\pi(s) = \mathbb{E}_\pi[G_t | s_t = s]$$

—— 状态价值：从 s 起，按 π 行动，所有可能 trajectory 的累计折扣回报的期望。逐项拆开看：

- $V^\pi(s)$ ：左边是要算的量， π 写在上标提醒这个值绑定到某个具体策略——同一个状态 s ，不同策略下价值不一样。
- $\mathbb{E}_\pi[\cdot]$ ：对"按 π 采样出来的随机性"取期望。这里的随机性有两个来源——动作 $a_t \sim \pi(\cdot | s_t)$ 和状态转移 $s_{t+1} \sim P(\cdot | s_t, a_t)$ ，两者一起决定 trajectory 怎么走。
- $G_t = \sum_{k=0}^{T-1-t} \gamma^k r_{t+k}$ ：从 t 时刻起的累计折扣回报（第 2.3 节里定义过，episodic 有限时长版本；无限时长 MDP 把上界换成 ∞ ）。
- $| s_t = s$ ：条件——固定起点是 s 。

一句话： $V^\pi(s)$ = "我现在处在 s ，从这里开始一直按 π 走下去，期望能攒到多少累计折扣回报"。

$$Q^\pi(s, a) = \mathbb{E}_\pi[G_t | s_t = s, a_t = a]$$

—— 动作价值：在 s 先选定 a 这一步、之后按 π 走，期望能拿多少累计折扣回报。和 V 的差别只在条件多了一项 $a_t = a$ ：

- $| s_t = s, a_t = a$ ：条件比 V 多了"第 0 步动作锁死为 a "。也就是说第一步动作不再由 π 决定，而是外部指定；从第二步 a_{t+1} 开始才回到 π 采样。
- 所以 $Q^\pi(s, a)$ 回答的是"如果我在 s 偏要先做 a 、之后老老实实按 π 走，期望回报多少"——这个"先指定一步再回到策略"的设定，正是后面比较不同动作好坏（advantage）的基础。

两者关系：

$$V^\pi(s) = \sum_a \pi(a | s) Q^\pi(s, a)$$


—— 状态价值是动作价值按策略加权平均。逐项：

- 左边 $V^\pi(s)$ ：状态价值，第一步动作交给 π 决定。

- $\sum_a$: 对所有可能的动作求和（连续动作空间换成积分）。
- $\pi(a | s)$: 策略在 s 选动作 a 的概率，是加权重。
- $Q^\pi(s, a)$: 在 s 强行先选 a 之后再按 π 走的回报。

直觉: " π 选动作"等价于"按 $\pi(a | s)$ 的概率挑一个 a , 然后用 $Q^\pi(s, a)$ 评估它"——把所有动作的 Q 按其被选中的概率加权平均, 就还原成 V 。

V(s) vs Q(s,a): 两者都从 s 出发, 差别在第一步动作怎么决定



相同点: 都是「从 s 起, 按 π 行动」的累计折扣回报的期望 | 差别: V 对所有动作加权平均, Q 把第一步定住

左侧 $V^\pi(s)$ 把第一步交给 π , 三条分支按 $\pi(a | s)$ 加权平均; 右侧 $Q^\pi(s, a_2)$ 把第一步钉死成 a_2 , 其他分支灰掉。底部公式块就是上面 $V^\pi = \sum_a \pi(a | s)Q^\pi(s, a)$ 的代数与几何对应。

3.3 优势 advantage

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$$


—— 优势: 在 s 选 a 比"按当前策略平均水平"好多少。 $A > 0$ 表示这个动作比平均好, $A < 0$ 表示比平均差。

A 的"零均值化"性质: 在状态 s 下, 按当前策略 π 采动作并对 $A^\pi(s, a)$ 取期望, 结果恒等于 0:

$$\mathbb{E}_{a \sim \pi(\cdot|s)} [A^\pi(s, a)] = \mathbb{E}_{a \sim \pi(\cdot|s)} [Q^\pi(s, a)] - V^\pi(s) = V^\pi(s) - V^\pi(s) = 0$$

中间一步用了第 3.2 节末尾的关系 $V^\pi(s) = \sum_a \pi(a | s)Q^\pi(s, a) = \mathbb{E}_{a \sim \pi} [Q^\pi(s, a)]$, 也就是"按策略加权平均的 Q 就是 V "——既然减去的 V 正好等于 Q 的均值, 剩下的 A 自然均值为 0。

优势 $A(s,a) = Q(s,a) - V(s)$: 按 π 加权后均值为 0



把每个动作的 Q 画成柱、 V 画成水平基线，柱顶到基线的有符号距离就是 A ——绿色（高于平均）和红色（低于平均）按 π 加权后正好抵消，这就是“零均值化”的几何意义。

这件事在策略梯度里非常关键，有两条好处：

1. 方向更干净：策略梯度形式上是 $\nabla_{\theta} J \approx \mathbb{E} [\nabla_{\theta} \log \pi(a | s) \cdot A(s, a)]$ （为什么是这个形式？严格推导留到第 5 节）。把 A 当成对每个动作的“打分”。 A 均值为 0 意味着——平均水平的动作（ $A = 0$ ）不会推动梯度， $A > 0$ 的动作概率被往上拉、 $A < 0$ 的被往下压， π 的更新方向天然就是“把分布往高于平均的动作那边挪”。这比直接用 Q （一个非负的“绝对值”）当权重重要清爽得多。
2. 无偏地降方差：可以证明用 $V^{\pi}(s)$ 当 baseline（即用 $A = Q - V$ 替代 Q ）不改变策略梯度的期望，但能显著降低估计方差——这就是后面 baseline / actor-critic / PPO 都要训一个 V_{ϕ} 网络的根本动机。这个无偏性证明放在第 6 节细讲，这里先记住： A 均值为 0 是这个降方差技巧成立的理论锚点。

四、目标函数：期望累计回报

RL 的训练目标：找一组 θ 让按 π_{θ} 走出来的轨迹期望回报最大。

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} [R(\tau)] = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{T-1} \gamma^t r_t \right]$$

逐项拆开看：

- τ 是一整条轨迹。回忆第 2.2 节的定义： $\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \dots, s_{T-1}, a_{T-1}, r_{T-1}, s_T)$ ——从初始状态一直到 episode 结束的全部（状态，动作，奖励）序列。
- $R(\tau) = \sum_{t=0}^{T-1} \gamma^t r_t$ 是这条轨迹的累计折扣回报，是 τ 的函数（确定一条 τ 就确定了 R ）。
- τ 的分布由三件事联合决定，按时间步展开：

$$p_{\theta}(\tau) = \underbrace{\rho_0(s_0)}_{\text{环境给的初始状态分布}} \cdot \prod_{t=0}^{T-1} \underbrace{\pi_{\theta}(a_t | s_t)}_{\text{策略选动作}} \cdot \underbrace{P(s_{t+1} | s_t, a_t)}_{\text{环境的状态转移}}$$

其中 $\pi_{\theta}(a_t | s_t)$ 就是"参数为 θ 的策略在 s_t 处给出动作分布"——这部分依赖 θ ，是可优化的。而初始状态分布 ρ_0 和转移概率 P 是环境本身给定的（CartPole 的物理仿真、Atari 的游戏引擎），不依赖 θ ，不能优化但仍然参与生成 τ 。

- $\mathbb{E}_{\tau \sim \pi_{\theta}}[\cdot]$ 的写法是简写：之所以下标只写 π_{θ} 而省略 ρ_0 与 P ，是因为这两项是固定的、不依赖 θ ，把唯一依赖 θ 的策略拎出来当"分布标签"更直观。展开就是

$$J(\theta) = \sum_{\tau} p_{\theta}(\tau) \cdot R(\tau) \quad (\text{连续情况换成积分})$$

——枚举所有可能的轨迹，按其出现概率加权求和。

一句话总结： τ 是整条轨迹（由初始状态 + 策略 + 环境转移三部分联合采样而来，其中只有 π_{θ} 依赖 θ ），对它的累计奖励 $R(\tau)$ 取期望就是要最大化的目标 $J(\theta)$ 。

接下来要做的事：对 θ 求 J 的梯度，再用 P04 学的梯度下降（由于这里要最大化回报 J ，方向反过来——沿梯度同向走，即 $\theta \leftarrow \theta + \eta \nabla J$ ，习惯上叫"梯度上升"）调参数。问题是—— r_t 是环境给的，不可微；而且 τ 的分布本身依赖 θ 。直接对 J 求导的链式法则没法走通。

为什么链式法则走不通？分两层看：

1. 采样 + 环境这条路本身不可微。监督学习里梯度能一路从 loss 反向流回 θ ，是因为整条路径都是可微计算

图： $\theta \rightarrow \hat{y} \rightarrow L$ 。RL 里这条路径长这样： $\theta \rightarrow \pi_{\theta} \rightarrow a \rightarrow r$ ，两处都断了——

- 采样动作不可微： $a \sim \pi_{\theta}(\cdot | s)$ 是"按概率抽一个样本"的离散随机操作。概率 $\pi_{\theta}(a | s)$ 本身是 θ 的可微函数，但"抽出哪个 a "这一步没有梯度（好比抛骰子，骰子各面概率你能调，"抛出的点数"不是参数的可微函数）。
- 环境是黑盒： $r = R(s, a)$ 由物理仿真 / 游戏引擎 / 冻结的 RM 网络等决定，不在你的计算图里，没法 `backward()` 穿过去。

2. 显式展开求导也得不到可估计的期望。把 J 写成积分形式 $J(\theta) = \sum_{\tau} p_{\theta}(\tau) R(\tau)$ ，注意 $R(\tau)$ 是一条固定轨迹上的奖励之和、与 θ 无关（ $\nabla_{\theta} R = 0$ ），只有 $p_{\theta}(\tau)$ 依赖 θ 。朴素求导得到：

$$\nabla_{\theta} J(\theta) = \sum_{\tau} \nabla_{\theta} p_{\theta}(\tau) \cdot R(\tau)$$

形式上没错，但这不是一个期望——是对所有可能轨迹的求和（CartPole 500 步、动作空间 2，可能轨迹就有 2^{500} 条；LLM 更夸张），枚举不动。要用蒙特卡洛采样估计就必须写成 $\mathbb{E}_{\tau \sim \text{某分布}}[\cdot]$ 的形式；可上式右边的 $\nabla_{\theta} p_{\theta}$ 是"概率的梯度"，可正可负、加起来不为 1，没法直接当成采样分布。而且 $p_{\theta}(\tau)$ 含有环境转移 P 这个未知项，本身也写不出闭式表达式。

Policy Gradient 定理就是解决这一步的关键工具——用 log-derivative trick $\nabla_{\theta} p_{\theta} = p_{\theta} \cdot \nabla_{\theta} \log p_{\theta}$ 把上式变成 $\mathbb{E}_{\tau \sim \pi_{\theta}}[\nabla_{\theta} \log p_{\theta}(\tau) \cdot R(\tau)]$ ，重新认成"按 p_{θ} 采样的期望"，蒙特卡洛就能估了。而且 $\log p_{\theta}(\tau)$ 里环境部分（ ρ_0 与 P ）不依赖 θ 、求导直接归零，环境继续当黑盒即可——具体推导见第 5 节。

五、Policy Gradient 定理

定理（不严谨叙述）：

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot G_t \right]$$

直觉读法（最值得记的一段话）：

对每条轨迹的每一步 (s_t, a_t) ，把"在这个状态下选这个动作的对数概率"求一次梯度，再乘上从这一步开始拿到的累计回报 G_t ——这就是策略梯度的方向。

直觉：

- G_t 大（这步之后总收益高）→ 把 $\log \pi_{\theta}(a_t | s_t)$ 大幅推大，下次更愿意在 s_t 选 a_t
- G_t 小但为正 → 仍然是推大，只是推得弱——注意这一点：只要回报是正的，朴素版公式对采到的每个动作都在加大概率（CartPole 这种 G_t 恒正的环境里尤其明显），"比平均差的动作被压下去"要等第 6 节引入 baseline 之后才字面成立
- G_t 为负 → 把 $\log \pi_{\theta}(a_t | s_t)$ 推小，下次更不愿意在 s_t 选 a_t

这就是 RL 的"试错—强化"机制用一条公式写出来的样子。最关键的一点是：这条公式不需要对环境的奖励 r_t 求导——只需要对策略对数概率求导，环境怎么算奖励完全是黑盒。

5.1 为什么策略梯度是这个形式：log-derivative trick

为什么梯度里会冒出一个 $\nabla_{\theta} \log \pi_{\theta}$ ？关键的难点和技巧如下。

难点：目标 $J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}}[R(\tau)]$ 是对"按 π_{θ} 采样出来的轨迹"取期望——参数 θ 同时影响被采样的分布本身。展开成积分就是

$$J(\theta) = \int p_{\theta}(\tau) \cdot R(\tau) d\tau$$

——其中 $p_\theta(\tau)$ 是按 π_θ 生成轨迹 τ 的概率。 θ 藏在 p_θ 里，没法把 ∇_θ 直接搬进期望符号、像监督学习那样对一个固定分布上的损失求导。

技巧：用恒等式

$$\nabla_\theta p_\theta(\tau) = p_\theta(\tau) \cdot \nabla_\theta \log p_\theta(\tau)$$

——这就是 log-derivative trick（也叫 score function trick）。它来自微积分的链式法则： $\nabla_\theta \log p_\theta = \frac{\nabla_\theta p_\theta}{p_\theta}$ ，两边乘 p_θ 整理一下即得。把它代入梯度：

$$\nabla_\theta J(\theta) = \int \nabla_\theta p_\theta(\tau) \cdot R(\tau) d\tau = \int p_\theta(\tau) \cdot \nabla_\theta \log p_\theta(\tau) \cdot R(\tau) d\tau = \mathbb{E}_{\tau \sim \pi_\theta} [\nabla_\theta \log p_\theta(\tau) \cdot R(\tau)]$$

——一前一后两步关键操作：先用恒等式把 $\nabla_\theta p_\theta$ 换成 $p_\theta \cdot \nabla_\theta \log p_\theta$ ，再把 $p_\theta \cdot (\dots)$ 重新认成“按 p_θ 采样的期望”。这样梯度就变成了一个可以用蒙特卡洛采样估计的期望——只要能采轨迹、能对 $\log \pi_\theta$ 求导就行，不需要对环境的奖励 R 求导（这正是上一段强调的“环境是黑盒”的来历）。

再展开 $\log p_\theta(\tau)$ ：一条轨迹的概率可以按时间步分解：

$$p_\theta(\tau) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi_\theta(a_t | s_t) \cdot P(s_{t+1} | s_t, a_t)$$

——初始状态分布 ρ_0 与转移概率 P 都不依赖 θ ，取 $\log$ 后对 θ 求导这两项直接归零，剩下：

$$\nabla_\theta \log p_\theta(\tau) = \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t)$$

把 $\nabla_\theta \log p_\theta(\tau) = \sum_t \nabla_\theta \log \pi_\theta(a_t | s_t)$ 代回到 $\nabla_\theta J = \mathbb{E}_\tau [\nabla_\theta \log p_\theta(\tau) \cdot R(\tau)]$ ：

$$\nabla_\theta J(\theta) = \mathbb{E}_\tau \left[\left(\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t) \right) \cdot R(\tau) \right] = \mathbb{E}_\tau \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot R(\tau) \right]$$

——每一步 t 都把整条轨迹的总回报 $R(\tau)$ 当成它的权重。

接着把 $R(\tau)$ 按“过去”与“现在 + 未来”拆成两段：

$$R(\tau) = \sum_{t'=0}^{T-1} \gamma^{t'} r_{t'} = \underbrace{\sum_{t' < t} \gamma^{t'} r_{t'}}_{\text{过去}} + \underbrace{\sum_{t' \geq t} \gamma^{t'} r_{t'}}_{\text{现在与未来}}$$

——拆分的标准是“相对于当前考察的时间步 t ”。

过去那段乘上 $\nabla_\theta \log \pi_\theta(a_t | s_t)$ 后期望为 0——直觉上是因果性：“时间 t 选的动作不可能影响时间 $t' < t$ 已经发生的奖励”。下面给出严格证明，要的工具是 score function lemma：

$$\mathbb{E}_{a \sim \pi_\theta(\cdot | s)} [\nabla_\theta \log \pi_\theta(a | s)] = \sum_a \pi_\theta(a | s) \cdot \frac{\nabla_\theta \pi_\theta(a | s)}{\pi_\theta(a | s)} = \nabla_\theta \sum_a \pi_\theta(a | s) = \nabla_\theta 1 = 0$$

——任何归一化分布的“score” $\nabla_\theta \log \pi_\theta(a | s)$ 在该分布下期望恒为 0。连续动作空间把 $\sum_a$ 换成 $\int \pi_\theta(a | s) da = 1$ ，结论同。

把它套到我们要证的命题上，还需要一个工具：塔式期望（tower property / law of total expectation）—— $\mathbb{E}[X] = \mathbb{E}_Y[\mathbb{E}[X | Y]]$ ，意思是对一个随机量取期望，可以先固定某个随机变量 Y 算条件期望，再对 Y 本身取一层外层期望，结果不变。它的用处是把一个复杂期望拆成"先固定一部分变量、再对剩下的取期望"两层，方便把不依赖内层变量的项当常数提出来。

把对整条 τ 的期望按这个套路拆成两层——内层把"截止到 t 之前的历史" $h_{t-1} = (s_0, a_0, r_0, \dots, a_{t-1}, r_{t-1}, s_t)$ 当作已知（条件），只对 a_t 取期望；外层再对 h_{t-1} 自己取期望。给定 h_{t-1} 后， s_t 和"过去奖励" $\sum_{t' < t} \gamma^{t'} r_{t'}$ 都是常数（不依赖 a_t ），可以提到内层期望外面：

$$\mathbb{E}_{a_t \sim \pi_\theta(\cdot | s_t)} \left[\nabla_\theta \log \pi_\theta(a_t | s_t) \cdot \sum_{t' < t} \gamma^{t'} r_{t'} \middle| h_{t-1} \right] = \underbrace{\left(\sum_{t' < t} \gamma^{t'} r_{t'} \right)}_{\text{常数}} \cdot \underbrace{\mathbb{E}_{a_t \sim \pi_\theta(\cdot | s_t)} [\nabla_\theta \log \pi_\theta(a_t | s_t)]}_{= 0 \text{ (score function lemma)}} = 0$$

内层是 0，外层对 h_{t-1} 再取一层期望仍是 0。所以

$$\mathbb{E}_\tau \left[\nabla_\theta \log \pi_\theta(a_t | s_t) \cdot \sum_{t' < t} \gamma^{t'} r_{t'} \right] = 0$$

——这就把"因果性"这条直觉做实了。外层求和里凡是涉及"过去奖励"的项整体期望都是 0、可以安全删掉，剩下：

$$\nabla_\theta J(\theta) = \mathbb{E}_\tau \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot \sum_{t' \geq t} \gamma^{t'} r_{t'} \right]$$

后面那段稍微换一下指标，凑出第 2.3 节定义过的 $G_t = \sum_{k=0}^{T-1-t} \gamma^k r_{t+k}$ ：

$$\sum_{t' \geq t} \gamma^{t'} r_{t'} = \gamma^t \sum_{k=0}^{T-1-t} \gamma^k r_{t+k} = \gamma^t \cdot G_t$$

代回去得到严格形式：

$$\nabla_\theta J(\theta) = \mathbb{E}_\tau \left[\sum_{t=0}^{T-1} \gamma^t \cdot \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot G_t \right]$$

本章开头那条公式（以及绝大多数 REINFORCE / PPO 实现）把前面的 γ^t 吸收/忽略，写作：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot G_t \right]$$

为什么能省？两种常见处理：（a）LLM 对齐里 $\gamma = 1$ （episode 短、终止时一次给齐奖励），所以 $\gamma^t \equiv 1$ ，严格与简写完全一致；（b）即使 $\gamma < 1$ ，工程上常把 γ^t 因子省去——相当于改成"undiscounted average reward"或"每步同等重要"的近似目标，理论上是有偏的（更新规则不再精确优化原始 J ），但实战表现稳定、公式更简洁，社区已经默认这种写法。这一步小细节不影响理解，核心结构始终是"对 $\log \pi$ 求梯度，乘上一个动作的打分"。后面 baseline / advantage / PPO 的修补也都建立在这个简化版上。

一句话记忆： $\log \pi$ 提供"怎么调参才能改变动作概率"的方向， G_t （或后面换成 A_t ）提供"往哪个方向调、调多大"的力度与符号。后续 baseline / actor-critic / PPO 都是把 G_t 换成方差更小的打分（ $G_t - b$ 、 A 、GAE 等），骨架不变。

5.2 从期望到可算：蒙特卡洛采样


到这里我们写出来的 $\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}}[\dots]$ 是一个期望——理论上要对所有可能的 trajectory τ 求加权和。但 τ 的可能取值是天文数字（每一步动作组合爆炸），根本枚举不完。怎么办？蒙特卡洛采样（Monte Carlo, MC）：

$$\mathbb{E}_{x \sim p}[f(x)] \approx \frac{1}{N} \sum_{i=1}^N f(x_i), \quad x_i \stackrel{\text{iid}}{\sim} p$$

——从分布 p 里独立采 N 个样本 x_i ，把 f 在这 N 个样本上的取值平均一下，就是对真实期望的估计。公式右上角的 iid 是 independent and identically distributed（独立同分布）的缩写——意思是 N 个样本彼此独立（前一个采什么不影响后一个）、且都来自同一个分布 p ，这是下面三条性质（尤其方差按 $1/N$ 衰减）成立的前提。三条性质：

- 无偏：对任意 N ，估计的均值就等于真实期望（因为每个 $f(x_i)$ 的期望都等于 $\mathbb{E}_p[f]$ ）。
- 一致：大数定律保证 $N \rightarrow \infty$ 时样本均值收敛到真实期望。
- 方差按 $1/N$ 衰减：估计的标准差大约是 $\sigma_f / \sqrt{N}$ ——想把误差砍一半得采 4 倍样本，所以“降方差”（baseline、advantage）会比“加采样数”性价比高得多，这也是第 6 节的动机。

套到策略梯度上， p 就是“ π_{θ} 诱导的 trajectory 分布”， $f(\tau) = \sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot G_t$ 。实操：用当前策略跑 N 条 trajectory，对每条算出括号里那一部分，平均一下就得到 $\nabla_{\theta} J$ 的估计，拿去做一步梯度上升。这正是 REINFORCE 算法的核心内容——把“理论上是期望”翻译成“工程上是一批 rollout 的平均”。



整条流水线把“理论上是期望、工程上是一批 rollout 的平均”这件事画成了五个具体步骤：从 θ 出发驱动 π_{θ} 采 N 条 rollout（①），对每条 trajectory 算每步 G_t （②），再算 $\nabla \log \pi \cdot G_t$ （③），平均得到 MC 估计 $\nabla_{\theta} \tilde{J}$ （④），最后梯度上升一步把 θ 更新（⑤），新参数回到第一步开始下一轮——这也是第 7 节 REINFORCE 代码循环的骨架。

六、降方差：baseline 与 advantage

第 5 节末尾给出的策略梯度蒙特卡洛估计 $\nabla_{\theta} J \approx \frac{1}{N} \sum_i \sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot G_t$ ，理论上无偏、操作上能跑——但方差非常大：同一个 θ 跑两条 trajectory， G_t 可能差好几个数量级，梯度方向忽东忽西。直接拿去训会很慢甚至发散。

这一节先讲怎么用"减去一个 baseline"这条几乎不增加额外成本的技巧把方差大幅压下来，下一节再把 PG (policy gradient) + MC (Monte Carlo) + baseline 拼成最小可执行的算法 REINFORCE。

策略梯度的权重项是 G_t ，但 G_t 的"绝对值"对方向并不本质——重要的是"这次比平均好还是差"。把 G_t 减去一个 baseline b ：

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot (G_t - b(s_t)) \right]$$

关键前提： b 只能依赖 s_t （或更早的历史 h_{t-1} ），不能依赖 a_t ——否则下面的"零项"性质就破了，梯度会被引偏。


无偏性证明（结构和第 5 节"过去奖励期望为 0"的证明完全一样）：用塔式期望 + score function lemma。给定历史 h_{t-1} 后 s_t 已确定， $b(s_t)$ 就是一个常数（这就是"不能依赖 a_t "这条前提的用处），提到内层期望外面：

$$\mathbb{E}_{a_t \sim \pi_{\theta}(\cdot | s_t)} \left[\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot b(s_t) \middle| h_{t-1} \right] = b(s_t) \cdot \underbrace{\mathbb{E}_{a_t \sim \pi_{\theta}(\cdot | s_t)} [\nabla_{\theta} \log \pi_{\theta}(a_t | s_t)]}_{=0} = 0$$

内层是 0，外层再套一层期望仍是 0；对 t 求和后仍是 0。所以减去 $b(s_t)$ 不改变策略梯度的期望——即估计仍然无偏。

那为什么能降方差？期望不变，但方差 $\text{Var}[X - b]$ 取决于 b 与 X 的相关程度——选得好的 b （如接近 $\mathbb{E}[G_t | s_t] = V^{\pi}(s_t)$ ）能把"与状态强相关、与动作选择无关"的那部分波动从 G_t 里扣掉，剩下的就是更"纯净"的关于动作好坏的信号。严格说方差最小的 state-dependent baseline 是按梯度范数加权的期望回报，但实践中最常用、也接近最优的选择就是 $V^{\pi}(s_t)$ ——这就是 actor-critic 系训一个值网络 V_{ϕ} 当 baseline 的来历。

Baseline 降方差：期望不变，但散点更窄、梯度更稳



左图把 30 个 episode 的 G_t 直接画成散点， $\sigma \approx 72$ ；右图减去状态相关 baseline $V(s_t)$ 后散点立刻收紧， $\sigma \approx 26$ ，平均值仍稳定在 0 附近——这就是“期望不变（无偏）+ 方差大幅缩小”的几何直观。这里要区分两个“方差”：把所有 G_t 减去同一个常数（与 state 无关）时，散点自身的 σ 确实一动不动，但策略梯度估计的方差照样能显著下降——因为被平均的量是 $(G_t - b) \nabla \log \pi$ 而不是 G_t 本身，回报整体偏正时减掉一个常数就能让正负样本的拉扯相互抵消（常数 baseline 正是 Williams 1992 原始 REINFORCE 论文的做法）；依赖状态的 baseline $V(s_t)$ 则更进一步，把“状态间”的那部分波动也扣掉，连散点都收紧了。

最简单的 baseline 是把 batch 里所有 G_t 减去它们的均值——一行代码，立即见效；实战里通常顺便再除以标准差做归一化（注意：除以 std 已经超出 baseline 理论的范围，是对梯度的整体缩放，严格说让估计有偏，但能把更新步幅稳定到同一量级，实践中几乎总是利大于弊）：

```
returns = (returns - returns.mean()) / (returns.std() + 1e-8)
```

更进一步，把 $b(s_t)$ 换成 状态价值估计 $V^\pi(s_t)$ （再训一个值网络 V_ϕ 来估计），就得到 $G_t - V_\phi(s_t)$ ——这就是优势（advantage）的估计。当今主流的 actor-critic 系（A2C / PPO / GAE）核心都是这个想法的精修版本——更具体的 PPO / GRPO 工程细节留到第 7 节末尾配合 REINFORCE 一起说。

这里先记一个直觉：baseline 是从“理论 OK 但训不动”的朴素 PG 走向工业级策略梯度的第一步。下一节就把 PG + MC + baseline 拼成完整算法 REINFORCE，并在 ipynb 里跑两次（带 / 不带 baseline）把这一节的方差差距直接画出来看。

七、REINFORCE 算法

把第 4-6 节拼起来——policy gradient 给方向（第 4-5 节）、蒙特卡洛把期望落到 rollout 上（第 5.2 节）、baseline 把方差压下来（第 6 节）——就得到最经典的策略梯度算法 REINFORCE（蒙特卡洛策略梯度）。先看不带 baseline 的极简伪代码（教科书"hello world"版本）：

```
Initialize policy network  $\pi_\theta$  (随机初始化)

for episode in 1, 2, ...:
    1. 用当前  $\pi_\theta$  跑一条完整 trajectory
        $\tau = (s_0, a_0, r_0, \dots, s_{T-1}, a_{T-1}, r_{T-1})$ 
    2. 从后往前算每个时刻的 return  $G_t$ 
        $G_{T-1} = r_{T-1}$ 
        $G_t = r_t + \gamma G_{t+1} \quad (t = T-2 \dots 0)$ 
    3. 估计策略梯度:
        $\hat{g} = \sum_t G_t \cdot \nabla_\theta \log \pi_\theta(a_t | s_t)$ 
    4. 上升:
        $\theta \leftarrow \theta + \eta \hat{g}$           (== 下降  $-\hat{g}$ ; P04 的优化器一样能用)
```

关于 N ：第 5.2 节的公式是 N 条 trajectory 求平均的通式，这里伪代码取了 $N = 1$ （每跑完一条 episode 就更新一次），是 Williams 1992 原始 REINFORCE 的写法。 $N = 1$ 仍是 ∇J 的无偏估计，只是单次方差大——靠 SGD 在时间维度上跨 episode 隐式平均，加上 CartPole 这种短任务本身够稳，几百个 episode 累积下来就够收敛。真到 PPO / GRPO 这类工业场景，会显式并行跑几十~几千条 rollout 再一次性更新（ $N \gg 1$ ）以进一步压方差——这属于"工程修补"，REINFORCE 的"hello world"版本不引入。

放进 PyTorch 的训练循环里写法（把第 6 节的 baseline 做成开关 `use_baseline`，方便 ipynb 里跑两次对比方差差距）：

```
# 假设 policy 是  $4 \rightarrow 32 \rightarrow 2$  的 MLP, 输出 raw logits
# 状态  $s \in \mathbb{R}^4$  (CartPole); 动作  $a \in \{0, 1\}$ 
# gymnasium 的 step() 返回 5 元组 (obs, reward, terminated, truncated, info)
# gymnasium 的 reset() 返回 (obs, info) 2 元组
# 老 gym 的 step() 是 4 元组 (obs, reward, done, info)、reset() 返回单值 obs——迁移老代码时这两处都要改

for ep in range(n_episodes):
    # ---- ① rollout: 用当前策略走完一条 episode ----
    # 每个 episode 用不同 seed, 保证初始状态多样、避免过拟合到某个特定起点
    # 解包: s — 初始状态 / 观测 (observation)。CartPole-v1 是 4 维 numpy 数组 [cart_pos, cart_vel, pole_angle, pole_ang_vel]
    #      _ — info 字典 (Python 惯例: 变量名 _ 表示"知道返回了这个值, 但用不到, 直接丢弃"); CartPole 这里通常是空 dict
    s, _ = env.reset(seed=seed * 1000 + ep)
    # REINFORCE 是蒙特卡洛 (MC) 算法: 必须等整条 episode 跑完才能算  $G_t$ , 所以这里先把整条轨迹缓存下来
    states, actions, rewards = [], [], []
    while True:
        # CartPole 的 obs 默认是 float64 numpy 数组; nn.Linear 默认权重是 float32, dtype 不匹配会报错
        s_t = torch.as_tensor(s, dtype=torch.float32)
        logits = policy(s_t)  # (2,) raw logits — 不要在 forward 末尾加 softmax
        # torch.distributions.Categorical: 用 PyTorch 自带的类别分布把神经网络输出的 logits 包成一个概率分布对象, 方便后面 sample 动作、算 log 概率
        # 用 logits 构造 Categorical 比用 probs 数值更稳: 内部走 log_softmax, 避免 softmax 后再 log 的精度损失
        dist = torch.distributions.Categorical(logits=logits)
```

```

# dist.sample(): 按 logits 对应的 softmax 概率采样, 返回一个离散动作 id
# 训练阶段一定要 sample (保留探索); 评测时才换成 argmax 贪心
# .item() 把 0-d tensor 转 Python int — 同时也切断了 autograd 图 (rollout 阶段不需要梯度)
a = dist.sample().item()
s2, r, terminated, truncated, _ = env.step(a)
# 注意 append 的是"采样前那个 s" (对应 logits 算出来的状态), 不是 step 之后的 s2
states.append(s); actions.append(a); rewards.append(r)
s = s2
# terminated = 环境自然结束 (杆倒下); truncated = 外部超时截断 (达到 500 步上限)
# CartPole 这种短任务两者合并处理无妨; 理论上 truncated 时还应该 bootstrap 估计未来回报
if terminated or truncated:
    break

# ---- ② 算每步的 return G_t ----
# discount_returns 从后往前递推  $G_t = r_t + \gamma G_{t+1}$ ,  $O(T)$ ; 正向写成双层求和会变  $O(T^2)$ 
returns = torch.tensor(discount_returns(rewards, gamma), dtype=torch.float32)
# 1 baseline: 把 returns 减去本条 episode 的均值、再除以标准差 — 简单但极有效
# 注意: 这个均值/标准差是从同一条轨迹的全部  $G_t$  算出来的、依赖了轨迹里所有动作,
# 不满足 P05 第 6 节无偏性证明的前提 (baseline 只能依赖状态、不能依赖动作),
# 所以严格说它是"有偏但实战非常有效"的近似; 除以 std 更是对梯度的整体缩放—
# 用一点偏差换取更新步幅稳定、方差大降, REINFORCE 实现里几乎人人都这么写
# 加 1e-8 防止 std=0 (episode 极短、returns 全相等时) 触发除零
if use_baseline:
    returns = (returns - returns.mean()) / (returns.std() + 1e-8)

# ---- ③ 重新 forward 整条 trajectory, 拿到  $\log \pi(a|s)$  ----
# 为什么不在 rollout 时顺手存 log_prob? — 那样会把一张巨大的 autograd 图保留到 episode 末尾, 浪费显存
# 现在的做法: rollout 时 .item() 切断图, 更新前再批量 forward 一次拿带梯度的 log_prob
# 先 np.array 再转 tensor, 比直接对 list-of-arrays 调 torch.tensor 快一个数量级 (官方文档有警告)
states_t = torch.as_tensor(np.array(states), dtype=torch.float32)
# 离散动作 id 必须用 long — Categorical.log_prob 内部按整数索引取概率, float 会报 dtype 错
actions_t = torch.as_tensor(actions, dtype=torch.long)
logits_t = policy(states_t) # (T, 2) — 整条轨迹一次 forward, 远快于逐步
循环
# log_prob(a) 自动按动作 id 在第 -1 维取对应那一项的 log 概率, 等价于 log_softmax(logits)[range(T),
actions]
log_probs = torch.distributions.Categorical(logits=logits_t).log_prob(actions_t) # (T,)

# ---- ④ REINFORCE loss =  $-E[\log \pi(a|s) \cdot G]$  ----
# 取负号: PyTorch 优化器做 minimization; 要"最大化 J"就把 loss 写成 -J (和 cross-entropy 取负号同源)
# 用 .mean() 而不是 .sum(): 对 T 取平均, 让学习率不随 episode 长度漂移 (否则长 episode 自动放大梯度)
# returns 是常数 (不依赖  $\theta$ ), 梯度只通过 log_probs 这一路传回 policy 参数
loss = -(log_probs * returns).mean()
optim.zero_grad() # 别忘清零, PyTorch 默认累加梯度
loss.backward()
optim.step() # 沿  $-\nabla \text{loss}$  走一步 == 沿  $+\nabla J$  走一步 (即"梯度
上升")

```

其中 `discount_returns` 是一个手写的小函数, 从后往前把 $G_t = r_t + \gamma G_{t+1}$ 算出来:

```

def discount_returns(rewards, gamma):
    """从后往前算  $G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots$  (P05 第 2.3 节公式)"""
    G = 0.0
    out = []
    for r in reversed(rewards):
        G = r + gamma * G
        out.insert(0, G)
    return out

```

注意 loss 那行的负号——PyTorch 优化器是做最小化的，要"上升 J"就把 loss 写成 $-(...)$ 。这跟 cross-entropy 取负号同源——都是把"最大化"翻译成"最小化"。

公式 vs 代码：次序看着相反，其实完全等价。第 5 节推出来的策略梯度长这样：

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot G_t \right]$$

操作顺序是：对每一步先求 $\nabla \log \pi \rightarrow$ 乘 $G_t \rightarrow$ 对 t 求和 $\rightarrow$ 对 τ 求期望。但代码里 `loss = -(log_probs * returns).mean() + loss.backward()` 的顺序却反过来了：先逐元素算 $\log \pi(a_t | s_t) \cdot G_t \rightarrow$ 对 t 取均值 $\rightarrow$ 再让 autograd 一次性回传梯度。两种次序之所以能给出相同的参数更新，靠的是三件事：

(1) 梯度算子是线性的——求和与 ∇ 可以随便换次序：

$$\nabla_{\theta} \left(\sum_t f_t(\theta) \right) = \sum_t \nabla_{\theta} f_t(\theta)$$

(2) G_t 是常数（不依赖 θ ）。代码里 `returns` 来自 env 给的 `rewards`、没接进 autograd 图（无 `grad_fn`），所以反向传播时被当成常数因子直接拎到 ∇ 外面：

$$\nabla_{\theta} (\log \pi \cdot G) = G \cdot \nabla_{\theta} \log \pi$$

(3) `mean` 和 `sum` 只差常数 $1/T$ ，被学习率吸收。公式里写 $\sum_t$ ，代码里写 `.mean()` $\equiv \frac{1}{T} \sum_t$ ；这个 $1/T$ 整体缩放梯度，等价于把 `lr` 调大 T 倍。代码选 `.mean()` 是为了让有效步长不随 episode 长度（CartPole 初期十几步、训到末期 500 步）漂移。

合起来看，代码实际跑的就是"先把方括号里的 scalar 算成 `loss`、再 `loss.backward()` 求梯度"——把这个顺序原样写成公式（基于 1 条采样的 τ ）：

$$\nabla_{\theta} \mathcal{L} = \nabla_{\theta} \left[-\frac{1}{T} \sum_{t=0}^{T-1} \log \pi_{\theta}(a_t | s_t) \cdot G_t \right]$$

方括号里就是 `loss = -(log_probs * returns).mean()` 这个 scalar 值， ∇_{θ} 作用在最外层对应 `loss.backward()`。跟第 5 节理论公式相比有三处差异，但都不改变梯度方向：负号把"最大化 $\tilde{J}$ "翻译成"最小化 $\mathcal{L}$ "（被 `optim.step()` 里的 $\theta \leftarrow \theta - \text{lr} \cdot \nabla_{\theta} \mathcal{L}$ 再翻回正方向）； $1/T$ 是工程缩放，被 learning rate 吸收；单条 τ 替代 $\mathbb{E}_{\tau}$ 是蒙特卡洛单样本估计——估计本身无偏，方差大就是第 6 节 baseline 要解决的事。autograd 偏好这种"先聚合成 scalar 再 ∇ "的写法是因为它只需要一张前向图、一次反向就能算出所有参数的偏导，比对每一步 t 单独求 $\nabla \log \pi_{\theta}$ 再手工累加省事得多。

`terminated` vs `truncated` 是 gymnasium 0.26+ 的新约定：`terminated=True` 表示环境本身结束（CartPole 杆倒下、Atari 游戏死亡），`truncated=True` 表示外部超时强制截断（如 CartPole-v1 设了 500 步上限）。计算回报时通常两者都触发"episode 结束"，但理论上 `truncated` 时还应该 bootstrap 估计未来回报；CartPole 这种短任务忽略这个细节也无妨。

REINFORCE 的优缺点：

优点	缺点
极简，几乎是 RL 的"hello world"	方差大——同一个 θ 跑两条轨迹 G 可能差很多（第 6 节的 baseline 就是为此而设）
不需要任何关于环境的额外假设	每步样本只用一次（on-policy），样本效率低
思想直接、容易写对	在 LLM 这种长序列、稀疏奖励的设置下几乎不能直接用

加 baseline 是迈向"工业级策略梯度"的第一步——后面 PPO / GRPO 都是 REINFORCE + 几条工程修补。展开之前先点清两个绕不开的概念，因为读 PPO 论文一定会撞见：

- on-policy vs off-policy: REINFORCE 必须用当前 π_θ 采的 trajectory 来更新 π_θ ——一旦 θ 走了一步，旧数据就"过期"了，要重新采。这叫 on-policy，最大的缺点是样本贵（每条 rollout 只用一次就扔）。允许用别的策略（如旧版本的 $\pi_{\theta_{old}}$ ）采的数据去更新当前 π_θ ，叫 off-policy——样本利用率高，但需要修正"两个策略分布不一样"带来的偏差。
- 重要性采样（importance sampling, IS）：就是那个"修正项"。要在分布 p 下算 $\mathbb{E}_p[f(x)]$ 、却只有从 q 采的样本，可以写 $\mathbb{E}_p[f(x)] = \mathbb{E}_q\left[\frac{p(x)}{q(x)}f(x)\right]$ ——每个样本乘上 IS 比率 p/q 即可无偏。套到 RL 上， $p = \pi_\theta$ 、 $q = \pi_{\theta_{old}}$ ，IS 比率就是 $r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$ 。

有了这两条，PPO / GRPO 就好理解了：

- PPO = REINFORCE 的策略梯度里把 $\nabla \log \pi$ 替换成"IS 比率 $r_t(\theta) \cdot \text{advantage}$ "，让 $\pi_{\theta_{old}}$ 采的一批数据可以多步更新 π_θ （样本效率提升一个数量级）；再用 clip 把 $r_t(\theta)$ 裁到 $[1 - \epsilon, 1 + \epsilon]$ 防止单步走太远把策略推爆——典型 $\epsilon = 0.2$ 。advantage 用 critic 网络 V_ϕ + GAE（generalized advantage estimation，把多步 TD 误差加权混合）估。
- GRPO（DeepSeek-R1 用的）= 在 PPO 的基础上去掉 critic 网络：对同一个 prompt 采 N 条 rollout，把这一组里的 reward 做组内归一化（减均值除以标准差）当 advantage——省一个网络的训练成本，特别适合 LLM 这种 "采样贵 + 一个 prompt 自然就能采多条" 的场景。

真正读懂 PPO 的捷径就是先把 REINFORCE 的代码自己写一遍——这正是本章 ipynb 实战部分的核心。下一节把这套语言整体映射到 LLM 对齐。

八、从 RL 到 LLM 对齐

把 RL 的语言映射到 LLM 训练上：

RL 概念	LLM 对齐里的对应物
状态 s_t	prompt + 已经生成的前 $t - 1$ 个 token

RL 概念	LLM 对齐里的对应物
动作 a_t	第 t 步生成的下一个 token
策略 $\pi_\theta(a \mid s)$	LLM 在当前上下文的输出 softmax 分布
转移 $P(s' \mid s, a)$	确定性: "拼接上新 token"
即时奖励 r_t	生成中间几乎都是 0; 终止时由 RM 或可验证规则一次给出
episode 终止	生成 EOS / 到最大长度
折扣因子 γ	一般取 1 (episode 短、奖励集中在末尾)
累计回报 G_t	终止时的总奖励 (中间步 G_t 几乎等于终止奖励)
优势 A_t	总奖励减去 baseline; GRPO 里就是组内归一化的回报
策略梯度	$\nabla_\theta \log \pi_\theta(\text{token}_t \mid \text{prompt} + \text{prev tokens}) \cdot A_t$
KL 约束 $\beta D_{\text{KL}}(\pi_\theta \parallel \pi_{\text{ref}})$	让对齐后的模型不要离 SFT 模型 / 预训练模型太远——P03 里讲过

表里最后一行的 π_{ref} 和那个 KL 惩罚项值得单独展开一下——很多读者第一次看 RLHF 公式都会卡在这两个分布到底是谁，为什么要把它们拉到一起。

π_{ref} 是参考策略 (reference policy)，通常就是 RLHF 开始之前的那个 SFT 模型——它由"预训练 base 模型 → SFT (监督指令微调)"两步得到，已经能正常生成流畅文本、会跟指令、会基本对话。进入 RLHF 阶段时：

- π_θ ：要训练更新的策略，初始化时复制一份 π_{ref} 的权重，再用奖励信号继续学。
- π_{ref} ：全程冻结，参数不参与梯度更新，只作为 KL 项里的"锚点"被引用。



为什么 loss 里要加 $\beta \cdot D_{\text{KL}}(\pi_\theta \parallel \pi_{\text{ref}})$ ？写出 KL 的定义就能看出几个性质：

$$D_{\text{KL}}(\pi_\theta \parallel \pi_{\text{ref}}) = \sum_x \pi_\theta(x) \log \frac{\pi_\theta(x)}{\pi_{\text{ref}}(x)}$$

数学层面有一个 corner case：若 $\pi_{\text{ref}}(x) = 0$ 而 $\pi_\theta(x) > 0$ ，那一项就是 $+\infty$ ——这个方向（被优化的 π_θ 在左）的 KL 叫 reverse KL，具有 mode-seeking（找单一峰）/ zero-forcing（零处归零）性质，会逼 π_θ 在 π_{ref} 没 mass（概率密度）的地方也别有 mass。对照的 forward KL $D_{\text{KL}}(\pi_{\text{ref}} \parallel \pi_\theta)$ 则正相反，是 mass-covering（强迫 π_θ 覆盖 π_{ref} 的所有峰）；RLHF / PPO 用的是 reverse KL。但 mode-seeking 这条只是个副作用；RLHF 加 KL 的真正动机是工程上的几条：

动机	没有 KL 会怎样
防止 reward hacking	RM 是个不完美的函数。 π_θ 漂得太远就会找到"RM 打高分但人类一看是胡言乱语"的对抗样本——KL 把 π_θ 锚在 RM 训练分布附近，让奖励信号停留在可信区域
保留语言能力	π_{ref} 已经能正常生成流畅文本；只优化 reward 会让模型为追高分变得啰嗦、复读、退化成模板 (mode collapse)
保持多样性	纯 RL 容易把分布塌到少数几个高奖励输出；KL 让分布形状不要离 π_{ref} 太远
训练稳定性	类似 trust-region：每步更新别太大，避免策略一步崩坏

超参数 β 控制锚定强度（典型 0.01 ~ 0.1）—— β 调大策略更保守地贴 SFT， β 调小更敢探索但更容易被 RM 钻空子。PPO / GRPO 都遵循这套"reward + KL"的复合目标，区别只在 advantage 怎么估、KL 怎么写（PPO 是显式加在 loss，部分实现把 KL 直接折进 reward）。

把这张表合并 P03 里"概率分布 / log-likelihood / KL"的概念，PPO / GRPO 的论文里几乎所有数学符号你都能找到位置。RLHF 的训练循环，框架长这样：

```
for prompt in dataset:
    # 1. rollout: 用当前 LLM 策略生成回答
    response = LLM_theta.generate(prompt)
    # 2. score: 奖励模型 / 规则给打分
    r = reward_model(prompt, response)          # 标量
    # 3. policy gradient: 把每个生成 token 当一步动作，用 r 当回报，做策略梯度
    loss = -sum_t log pi_theta(token_t | prompt + prev tokens) * A_t
           + beta * KL(pi_theta || pi_ref)      # 防止跑偏
    loss.backward()
    optimizer.step()
```

每一步在做的事，本质上就是 REINFORCE + 一些工程修补。

九、关键概念回顾

概念	一句话定义	LLM 对齐里的位置
MDP	状态、动作、转移、奖励、 γ 五元组	RL / 对齐论文的统一语言
策略 $\pi(a s)$	状态到动作的概率分布	LLM 本身就是一个策略
价值 $V^\pi(s)$	从 s 起按 π 行动的期望累计回报	actor-critic 中 critic 估计的对象
Q 函数 $Q^\pi(s, a)$	在 s 选 a 后按 π 行动的期望累计回报	DQN 等 value-based 方法估计的对象
优势 $A^\pi(s, a)$	$Q - V$ ，"这个动作比平均好多少"	PPO / GRPO 用来当策略梯度的权重

概念	一句话定义	LLM 对齐里的位置
累计回报 G_t	从 t 起的折扣奖励之和	LLM 里 episode 短，常等于终止奖励
策略梯度定理	$\nabla J = \mathbb{E}[\sum_t \nabla \log \pi(a_t s_t) \cdot G_t]$	一切 policy-based RL 的核心公式
REINFORCE	用 trajectory 蒙特卡洛估计策略梯度	PPO / GRPO 的祖先
Baseline / advantage	把 G_t 减去状态相关 baseline，降低方差	GRPO 用"组内归一化"实现，PPO 用 critic 网络估
KL 约束	$\beta \cdot D_{\text{KL}}(\pi_\theta \ \pi_{\text{ref}})$	RLHF / DPO 防止策略跑偏的软约束（惩罚项，加进目标，而非硬性约束 $\text{KL} \leq \delta$ ）

十、本章小结

这一章把强化学习里"够看懂 PPO 入门"的最小集合讲清楚了：

- MDP 的五元组 + 马尔可夫性给所有 RL 算法一个统一语言
- 策略 / 价值 / 优势——从动作的概率分布、到状态值、到"这步比平均好多少"，三层概念按需展开
- 策略梯度定理让"调参数最大化期望回报"有了可计算的形式，核心是 $\nabla_\theta \log \pi_\theta(a | s) \cdot G$
- REINFORCE 是策略梯度最朴素的实现，是 PPO / GRPO 的基础
- 降方差靠 baseline / advantage——这是从 REINFORCE 走到 PPO / GRPO 的关键修补
- 从 RL 到 LLM：状态 = prompt + 前缀、动作 = 下一个 token、奖励 = RM 或可验证规则；KL 约束防止策略跑偏

ipynb 里的实战部分会做这几件事：用 `gymnasium` 跑一遍 CartPole-v1，先看随机策略表现 → 实现一个 4→32→2 的策略网络 → 用 REINFORCE 训到收敛 → 加一个简单 baseline 看方差有多明显地下降；再演示一个最小的"LLM 风格"采样—评分—更新闭环，把上面"RL 到 LLM"的映射用代码验证一遍。

到这里，阶段 0 的五份预备知识就齐了——P01 张量与 autograd、P02 训练循环骨架、P03 概率与信息论、P04 优化器与调度、P05 强化学习——任何 LLM 学习路径里的"基础数学+ PyTorch 工具"都能从这五章里找到。这五份预备知识不要求一次读完，建议在用到对应工具时再回头补齐对应一章。